



UNIVERSITATEA DIN
BUCUREȘTI

FACULTATEA DE
MATEMATICĂ ȘI
INFORMATICĂ



SPECIALIZAREA TEHNOLOGIA INFORMAȚIEI

Proiect de diplomă

ANALIZA PREDICTIVĂ A SCORURILOR DE FILM BAZATĂ PE PROCESAREA POSTERELOR ȘI A METADATELOR CINEMATOGRAFICE

Absolvent

Gheorghe Andrei-Bogdan

Coordonator științific

Conf. Dr. Dumitru Bogdan Alexe

București, iunie 2026

Rezumat

Alegerea unui film a devenit o provocare zilnică mare din cauza volumului imens de conținut disponibil pe platformele de streaming, motiv pentru care notele de pe platforme precum IMDb joacă un rol foarte important. Această lucrare de licență își propune să exploreze dacă inteligența artificială poate anticipa succesul unui film, analizând nu doar datele sale statistice, ci și latura sa artistică și subiectivă. În acest scop, a fost dezvoltat un sistem inteligent capabil să analizeze posterul, descrierea și să îi evalueze detaliile tehnice, prezicând astfel nota finală. Rezultatele demonstrează că îmbinarea acestor trei perspective ajută algoritmul să creeze un clasament mult mai precis al filmelor. Proiectul se finalizează printr-o interfață grafică interactivă care permite utilizatorului să testeze diverse predicții ale sistemului, fie deja existente în baza de date, fie încărcate chiar de către el.

Abstract

Choosing a movie has become a major daily challenge due to the immense volume of content available on streaming platforms, which is why ratings on platforms like IMDb play a very important role. This bachelor's thesis aims to explore whether artificial intelligence can anticipate the success of a movie by analyzing not only its statistical data but also its artistic and subjective side. To this effect, an intelligent system was developed that is capable of analyzing the poster, the description, and evaluating its technical details, thereby predicting the final score. The results demonstrate that combining these three perspectives helps the algorithm create a much more accurate ranking of movies. The project culminates in an interactive graphical interface that allows the user to test various system predictions, either already existing in the database or uploaded by the user themselves.

Cuprins

1	Introducere	4
1.1	Contextul și Motivația	4
1.2	Obiectivele lucrării	5
1.3	Soluția propusă	5
2	Gestionarea Datelor	6
2.1	Colectarea și maparea metadatelor	6
2.2	Extragerea descrierilor prin API	7
2.3	Web Scraping pentru extragerea posterelor	7
2.4	Filtrarea și organizarea finală	8
3	Arhitectura Sistemului și Implementarea	9
3.1	Prelucrarea metadatelor	9
3.2	Prelucrarea textelor	10
3.2.1	Modele evaluate în faza exploratorie	10
3.2.2	Alegerea finală	10
3.3	Prelucrarea posterelor	11
3.3.1	Modele evaluate în faza exploratorie	11
3.3.2	Alegerea finală	11
3.4	Antrenarea Modelelor de Regresie	12
3.4.1	Principiul de funcționare	12
3.4.2	Justificarea alegerii algoritmului	12
3.5	Evaluarea Performanței și Metrica de Clasament	13
3.6	Fuzionarea Modelelor	16
3.7	Implementarea interfeței grafice	17
4	Concluzii	21
4.1	Sinteza lucrării și analiza performanței	21
4.2	Direcții viitoare de dezvoltare	22
	Bibliografie	23

Capitolul 1

Introducere

1.1 Contextul și Motivația

Motivația din spatele acestui proiect derivă dintr-o pasiune personală pentru cinematografie. Din perspectiva unei persoane care se uită destul de frecvent la filme, confruntarea cu un watchlist în continuă creștere și dificultatea de a selecta un singur titlu reprezintă un stres recurent. Timpul petrecut doar pentru a lua o decizie reflectă o problemă la scară largă a spectatorului modern, mai ales luând în considerare lansarea accelerată a unui număr tot mai mare de filme ce "trebuie" văzute.

În era digitală contemporană, expansiunea rapidă a platformelor de streaming a condus la o suprasaturare a conținutului audio-vizual disponibil. Această multitudine de opțiuni generează fenomenul menționat anterior, cunoscut sub denumirea de oboseală decizională. Astfel, platformele de recenzii și baze de date, cum sunt IMDb (Internet Movie Database) sau TMDb (The Movie Database), au devenit instrumente esențiale datorită faptului că nota finală medie oferită unui film servește drept un indicator important al calității acestuia.




Figura 1.1: Rating-ul filmului Interstellar.

Deși un spectator evaluează un film abia după ce l-a văzut, decizia inițială de a alege producția respectivă se bazează adesea pe identitatea sa proprie, care se manifestă în principal prin intermediul a trei ramuri, mai exact statisticile obiective (metadatele), structura narativă (descrierea) și identitatea vizuală (posterul).

1.2 Obiectivele lucrării

Tema esențială a acestei lucrări este de a descoperi dacă există o corelație măsurabilă între notele finale acordate de utilizatori și caracteristicile de prezentare menționate anterior. Mai exact, cercetarea își propune să investigheze în ce măsură succesul unui film poate fi anticipat strict pe baza atributelor sale, determinând totodată și modul în care aceste trei părți interacționează pentru a aproxima percepția umană generală.

În mod tradițional, predicția notei finale medii oferite unui film a fost abordată prin modele unimodale, care s-au bazat exclusiv pe metadata sau pe text. Scopul acestui proiect este de a investiga capacitățile anumitor algoritmi de inteligență artificială de a descifra corelațiile ascunse dintre imagini, text și metadata. Se dorește a se stabili dacă o rețea neuronală poate capta impactul de marketing al unui poster sau atractivitatea unei descrieri și dacă aceste predicții, odată combinate, pot depăși acuratețea modelelor clasice.

1.3 Soluția propusă

Pentru a răspunde acestor provocări de cercetare, a fost proiectat și dezvoltat un sistem inteligent hibrid, definit ca o arhitectură multimodală ce folosește Late Fusion. Această abordare permite procesarea independentă a fiecărui tip de date de către un model expert dedicat, înainte ca rezultatele lor să fie combinate pentru luarea deciziei finale.

Modelul propus utilizează arhitecturi de tip Transformer. Pentru analiza limbajului natural din descrierile filmelor, a fost integrat modelul pre-antrenat RoBERTa. Concomitent, analiza posterelor este realizată prin intermediul unei rețele Vision Transformer (ViT). Metadatale sunt prelucrate printr-un proces de vectorizare și encodare. Trăsăturile obținute din aceste trei surse distincte sunt ulterior direcționate către modele independente de Support Vector Regression (SVR), antrenate special pentru a mapa vectorii de caracteristici la nota alocată de platforma IMDb. Predicția finală a sistemului este rezultatul unei medii ponderate a acestor trei experți.




Figura 1.2: Diagrama sistemului multimodal.

Capitolul 2

Gestionarea Datelor

2.1 Colectarea și maparea metadatelor

Pentru a dezvolta acest sistem multimodal, a fost necesară o bază de date complexă, care să conțină metadate, descrieri detaliate și postere cât mai calitative. Deoarece nu exista un set de date public care să ofere toate aceste elemente unificate și gata de utilizare, primul pas a fost colectarea tuturor informațiilor, ajungând astfel la două platforme majore: IMDb și TMDB.

Datele brute inițiale au fost descărcate din setul non-comercial pus la dispoziție în mod oficial de platforma IMDb [1]. Pe parcursul etapei de documentare a fost găsit și un set de date public disponibil pe platforma Kaggle [7], însă informațiile din acesta s-au dovedit a fi insuficiente pentru acest proiect din cauza lacunelor și a lipsei de actualizări recente. Prin urmare, pentru a putea gestiona mai ușor informațiile necesare, a fost utilizat un fișier de legătură prin care s-a creat un dicționar de mapare exactă între ID-urile specifice IMDb și ID-urile corespondente din TMDB.

Un lucru la aparență important, dar dovedit rapid inconsistent a fost extragerea cuvintelor cheie din setul inițial, deoarece acestea erau stocate sub formă de texte ce imitau structura de dicționare din Python. Prin utilizarea funcției *literal_eval* din modulul *ast*, datele au putut fi parsate și extrase corect.

În final, au fost reținute doar informații esențiale precum genurile filmului, durata și anul lansării, formând astfel scheletul fișierului de metadate:

```
tt0816692,157336,Interstellar,2014,169.0,"Adventure,Drama,Sci-Fi"
```

2.2 Extragerea descrierilor prin API

Pentru componenta de procesare a limbajului natural a fost nevoie de descrierile filmelor. Deși inițial a existat un anumit dubiu cu privire la subiectivitatea acestor texte, în urma documentării s-a ajuns la concluzia că descrierile oferite de platforma TMDb păstrează un echilibru obiectiv optim, alegerea acestei surse fiind motivată, totodată, și de o accesibilitate mult mai facilă a datelor. Acestea au fost colectate prin interogarea API-ului oficial TMDb. Deoarece volumul de filme de procesat era foarte mare, o abordare clasică de descărcare secvențială ar fi generat un timp de execuție foarte mare din cauza timpilor de așteptare pentru răspunsul rețelei.

Soluția a fost implementarea unei procesări asincrone folosind clasa *ThreadPoolExecutor*, permițând descărcarea simultană a mai multor descrieri. Pentru a preveni pierderea datelor în eventualitatea în care conexiunea s-ar fi întrerupt, scriptul a fost gândit să salveze datele incremental pe disc.




Figura 2.1: Descrierea filmului Interstellar.

2.3 Web Scraping pentru extragerea posterelor

În cazul posterelor, descărcarea prin API-uri nu oferea mereu rezultate consistente din punctul de vedere al calității și al timpului, așa că s-a optat pentru tehnici de Web Scraping aplicate direct pe platforma IMDb. Scriptul creat accesează automat pagina fiecărui film, folosind un set de headere specifice (*User-Agent*) pentru a simula navigarea legitimă dintr-un browser.

URL-ul imaginii la rezoluție înaltă a fost extras direct din codul sursă HTML al paginii web folosind Regex. Mai exact, s-a vizat un tag "meta" folosit de obicei pentru partajarea pe rețele sociale.

La fel ca la extragerea descrierilor, și acest proces a fost paralelizat pentru a eficientiza execuția, iar imaginile au fost descărcate local.



Figura 2.2: Posterul filmului Interstellar.

2.4 Filtrarea și organizarea finală

Ultimul pas în pregătirea pipeline-ului a fost curățarea și organizarea informațiilor extrase, asigurând calitatea setului de date necesar învățării. În primă instanță, a fost aplicat un filtru pentru a elimina seriile sau alte formate de televiziune, păstrând strict producțiile de tip lungmetraj. Ulterior, au fost reținute doar filmele lansate începând cu anul 1990. Această decizie a asigurat o calitate vizuală relevantă a posterelor și a eliminat filmele foarte vechi, care ar fi putut introduce zgomot inutil în procesul de învățare al rețelei neuronale.

În urma aplicării tuturor acestor filtre, setul de date final a ajuns la o dimensiune de aproximativ 25.000 de filme distincte. Acest volum de date a asigurat o diversitate optimă, absolut necesară pentru antrenare.

Un alt aspect extrem de important pentru obiectivul lucrării, și în special pentru a putea avea măsurători cât mai amănunțite, a fost crearea unui clasament de referință. Filmele au fost sortate descrescător după rating-ul lor de pe IMDb, adăugându-se o coloană nouă numită *rank*. Acest lucru schimbă perspectiva evaluării: algoritmul nu trebuie doar să prezică o notă fixă izolată, ci mai degrabă să învețe cum se poziționează un film în raport cu celelalte.

`tt0816692,21(rank),8.7(rating)`

În final, datele au fost împărțite în trei submulțimi distincte: 1 - Antrenare (19.000), 2 - Validare (5.000) și 3 - Test (1.000). Aceste proporții au asigurat subseturi suficient de mari încât să poată satisface toate etapele ce urmează în procesul de antrenare a modelelor. În paralel, un script a organizat automat imaginile valide aferente filmelor reținute într-un folder specific *movie_posters*.

Capitolul 3

Arhitectura Sistemului și Implementarea

Odată ce pipeline-ul de date a fost finalizat și informațiile au fost împărțite corespunzător în subseturile de Antrenare, Validare și Test, următorul pas a constat în transformarea datelor brute într-un format matematic pe care modelele alese să îl poată ”înțelege”. Această etapă, cunoscută sub denumirea de **Extragerea Caracteristicilor**, a fost tratată independent pentru fiecare dintre cele trei modalități: metadate, text și imagine.

Acest capitol detaliază arhitectura fiecărui model testat în faza exploratorie, argumentând alegerile finale și prezentând modul în care datele au fost aduse la un numitor comun folosind vectori de caracteristici.

3.1 Prelucrarea metadatelor

Metadatele filmelor, constând în acest caz în anul lansării, durata și genurile cinematografice, reprezintă o sursă de informație fundamentală. Cu toate acestea, algoritmi de învățare automată necesită o standardizare atentă pentru a asigura un oarecare grad de stabilitate.

În primul rând, a fost necesară tratarea valorilor lipsă. Pentru anul lansării și durata filmului, ce au fost procesate inițial la nivel de cod ca șiruri de caractere, s-a făcut conversia la format numeric. Eventualele valori lipsă (N/A) au fost completate automat cu mediana întregului set de date. Alegerea medianei în detrimentul mediei aritmetice a fost o decizie menită să prevină distorsionarea datelor de către valorile extreme (outliers), cum ar fi filmele neobișnuit de lungi sau eventuale erori de pe IMDb.

Pentru genurile cinematografice situația a fost diferită. Din cauza faptului că un film poate aparține simultan mai multor genuri (ex: Aventură, Dramă, Science-Fiction), s-a aplicat o tehnică de tip **One-hot Encoding**. Fiecare gen unic a fost transformat într-o coloană binară distinctă, lucru ce permite algoritmului să izoleze influența fiecărui gen în

parte asupra notei medii finale.

3.2 Prelucrarea textelor

Pentru a capta esența textelor descriptive, a fost necesară utilizarea unor modele avansate de procesare a limbajului natural (NLP). În etapa de cercetare, au fost testate și evaluate mai multe arhitecturi înainte de a se stabili modelul final folosit.

3.2.1 Modele evaluate în faza exploratorie

Primul model luat în considerare a fost **BERT** (Bidirectional Encoder Representations from Transformers) [2]. Arhitectura sa aduce procesarea bidirecțională a textului, permițând rețelei să înțeleagă contextul unui cuvânt bazându-se atât pe cuvintele anterioare, cât și pe cele care urmează. Deși rezultatele extragerii de trăsături cu modelul *bert-base-uncased* au fost promițătoare, dimensiunea mare a modelului și resursele computaționale necesare au fost un factor decisiv.

În încercarea de a optimiza, s-a testat **DistilBERT** [8]. Acest model folosește o tehnică numită distilarea cunoștințelor (Knowledge Distillation), în care un model "profesor" (BERT) antrenează un model "elev" mai mic (DistilBERT). Deși DistilBERT reduce numărul de parametri cu aproximativ 40% și este cu 60% mai rapid, s-a observat o reducere a capacității de captare a detaliilor narative esențiale pentru a diferenția între ele textele descriptive ale filmelor.

3.2.2 Alegerea finală

Decizia finală a înclinat către **RoBERTa** (Robustly Optimized BERT Pretraining Approach) [6]. Acest model păstrează arhitectura de bază a lui BERT, dar aduce modificări importante în faza de pre-antrenare, cum ar fi:

- **Eliminarea obiectivului Next Sentence Prediction:** Rețeaua se concentrează exclusiv pe modelarea limbajului mascat, învățând reprezentări mai puternice ale secvențelor continue de text.
- **Mascarea Dinamică:** În loc să folosească același tipar de mascare a cuvintelor în fiecare epocă, RoBERTa generează noi măști la fiecare iterație a datelor, forțând modelul să învețe tipare semantice diferite și mai generalizabile.
- **Loturi de date mai mari:** Antrenarea cu batch-uri mult mai mari îmbunătățește gradientul și convergența.

Aceste optimizări i-au oferit modelului o capacitate superioară de a înțelege nuanțele dintr-un text descriptiv. Prin urmare, s-a folosit biblioteca *transformers*, iar descrierile

au fost trecute prin tokenizatorul ce a avut o limită de 512 tokeni. Pentru a obține o reprezentare generală a întregului text, a fost extras primul token din ultimul strat ascuns al modelului (token-ul special de clasificare), rezultând astfel într-un vector dens de caracteristici.

3.3 Prelucrarea posterelor

A treia modalitate a sistemului o reprezintă analiza identității vizuale a posterelor. Estetica unui poster reflectă adesea bugetul de marketing, genul filmului și publicul țintă, fiind un factor predictiv important. Pentru această sarcină au fost evaluate mai multe modele de vedere artificială distincte.

3.3.1 Modele evaluate în faza exploratorie

Primul candidat a fost **ResNet50** [4] ce introduce skip connections ca rezolvare a problemei dispariției gradientului în rețelele foarte adânci, permițând trecerea informației direct peste anumite straturi. Deși a oferit o bază bună de extragere a formelor și culorilor, analiza s-a dovedit prea concentrată pe trăsăturile mici.

Ulterior, s-a explorat **EfficientNet** [10]. Acest model inovează prin faptul că scalează rezoluția, lățimea și adâncimea rețelei pe baza unui coeficient, oferind o acuratețe bună raportată la numărul de parametri. Totuși, ambele modele s-au lovit de aceeași problemă, procesând imaginea prin ferestre glisante, deci având dificultăți în a capta corelații generale evidente (ex: legătura dintre titlul filmului din partea de jos și a actorului din centru).

3.3.2 Alegerea finală

Pentru a depăși limitările menționate și a menține o coerență arhitecturală cu modelul RoBERTa, decizia finală a fost utilizarea unui **Vision Transformer** [3], mai exact varianta *vit_b_16*.

Spre deosebire de celelalte convoluții, ViT abordează imaginea exact cum un model de limbaj abordează un text, adică ca pe o secvență. Modelul împarte posterul într-o matrice de regiuni (patch-uri), care, în acest caz, au dimensiuni fixe de 16×16 pixeli. Aceste regiuni sunt vectorizate, le este adăugată o encodare pozițională (pentru a reține locația lor în imagine) și sunt trecute prin mecanisme de **Multi-Head Self-Attention**.

Acest lucru îi permite rețelei să își dea seama instantaneu de relații generale evidente, calculând nivelul de importanță dintre oricare două regiuni din imagine, indiferent de distanța sau direcția dintre ele. Astfel, modelul captează imediat contrastul și gramatica și stilul vizual al posterului, elemente direct corelate cu succesul filmului.

3.4 Antrenarea Modelelor de Regresie

După obținerea reprezentărilor vectoriale din cele șapte surse, pasul următor a fost corelarea acestor trăsături complexe cu o valoare fixă, adică rating-ul IMDb. Pentru această sarcină, s-a optat pentru **Support Vector Regression** (SVR) [9].

3.4.1 Principiul de funcționare

Spre deosebire de regresia liniară standard, care folosește metoda OLS (Ordinary Least Squares) pentru a minimiza eroarea pe toate punctele din setul de date, având ca obiectiv:

$$\min \sum_{i=1}^n (y_i - f(x_i))^2 \quad (3.1)$$

SVR schimbă complet ideea. Modelul introduce o zonă de toleranță de lățime 2ϵ (intervalul $[f(x) - \epsilon, f(x) + \epsilon]$) în jurul funcției de predicție $f(x)$. Din punct de vedere matematic, algoritmul ignoră complet erorile, atât timp cât diferența absolută dintre valoarea reală y și valoarea prezisă $f(x)$ este mai mică sau egală cu ϵ :

$$|y - f(x)| \leq \epsilon \quad (3.2)$$

În acest caz practic (unde $\epsilon = 0.1$), modelul se concentrează exclusiv pe penalizarea instanțelor ce nu se află în această zonă. Pentru a realiza acest lucru, se folosește:

$$\min \left(\frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \right) \quad (3.3)$$

unde w reprezintă vectorul ponderilor, iar ξ_i variabilele care măsoară deviația punctelor ce cad în afara limitei ϵ .

Datele situate pe marginea zonei poartă denumirea de Vectori de Suport, iar ecuația hiperplanului de regresie este definită doar folosind acest subset de date, ceea ce face modelul extrem de eficient din punct de vedere al memoriei. Flexibilitatea deciziei se modifică direct prin intermediul parametrului C din ecuația de mai sus. O valoare mare pentru C penalizează drastic erorile, forțând modelul să se plieze mult mai strict pe date, în timp ce una echilibrată (precum $C = 1.0$) previne supraînvățarea și asigură o mai bună generalizare.

3.4.2 Justificarea alegerii algoritmului

Alegerea SVR ca mecanism predictiv nu a fost aleatorie, ci a răspuns în mod direct următoarelor provocări apărute pe parcurs:

- **Eficiența în spații cu dimensionalitate ridicată:** Trăsăturile extrase de arhitecturile Transformer, cum ar fi RoBERTa sau ViT, generează vectori denși. SVR se descurcă foarte bine în spații extinse dimensional, fiind mult mai puțin afectat comparativ cu modelele clasice.
- **Robustețea la valori de tip Outlier:** Rating-urile IMDb pot fi supuse subiectivității extreme, curentelor culturale sau fenomenelor de tip review bombing. Datorită variabilei epsilon, SVR limitează influența acestor anomalii statistice, oferind predicții mult mai stabile.
- **Capacitatea de modelare neliniară:** Relațiile dintre esența unui poster sau a unei descrieri și succesul filmului sunt profund neliniare. Aici intervine utilizarea unui kernel matematic, mai precis **Radial Basis Function** (RBF). Acesta mapează vectorii de intrare într-un spațiu cu dimensiuni infinite, unde corelațiile complexe devin liniar separabile, permițând algoritmului să descopere tipare cât mai abstracte.

Un pas important înaintea antrenării a fost standardizarea datelor folosind clasa *StandardScaler*. Algoritmii bazați pe măsurarea distanțelor în spațiu, așa cum este SVR, sunt extrem de sensibili la diferențe între valorile de intrare. Fără acest proces de scalare și uniformizare a varianței, caracteristicile numerice cu valori brute mai mari ar fi dominat complet decizia modelului.

```
Processing Metadata
Training on 19000 samples | Validating on 5000 samples
[Metadata] Fitting SVR model
Metadata COMPLETED!
MAE (Validation): 0.667
```

Figura 3.1: Exemplu: Antrenarea pe baza Metadatelor.

3.5 Evaluarea Performanței și Metrica de Clasament

În mod normal, performanța unui model de regresie este evaluată folosind metrici de eroare absolută sau pătratică, cele mai comune fiind MAE (Mean Absolute Error), MSE (Mean Squared Error) și coeficientul R^2 , definite prin următoarele ecuații:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3.4)$$

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (3.5)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (3.6)$$

unde y_i reprezintă nota reală, $\hat{y}_i$ nota prezisă, $\bar{y}$ media notelor reale, iar n numărul total de filme evaluate.

Tabel 3.1: Rezultatele modelelor individuale (Metrici de Eroare)

Model	MAE	MSE	R^2
Metadata	0.667	0.802	0.364
Text-RoBERTa	0.715	0.906	0.282
Text-DistilBERT	0.724	0.928	0.264
Text-BERT	0.729	0.944	0.252
Posters-ViT	0.777	1.059	0.161
Posters-ResNet50	0.790	1.089	0.136
Posters-EfficientNet	0.792	1.088	0.138

Totuși, evaluarea artistică a unui film are o doză incontestabilă de subiectivitate. Pre-dicția exactă a unui rating este o sarcină aproape nerealistă și adesea irelevantă din punct de vedere practic. Prin urmare, focusul evaluării a fost mutat pe capacitatea sistemului de a realiza un clasament în conformitate cu cel existent, fiind destul de relevant dacă modelul poate ierarhiza corect filmele calitative în defavoarea celor slabe. Performanța a fost măsurată utilizând doi coeficienți principali de corelație a pozițiilor în clasamente:

- **Coeficientul Spearman (ρ):** reprezintă o alternativă la corelația clasică Pearson. În loc să măsoare liniaritatea directă a valorilor absolute, coeficientul Spearman transformă mai întâi rating-uri în poziții în clasament, formula fiind dată de ecuația:

$$\rho = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)} \quad (3.7)$$

unde d_i reprezintă diferența dintre rangul notei reale și rangul notei prezise, iar n numărul total de observații. Astfel, ρ evaluează cât de strânsă este relația dintre ierarhia reală și cea prezisă. Un scor ridicat indică faptul că, pe măsură ce nota reală a unui film se modifică, modelul tinde să prezică o valoare concordantă, păstrând ordinea, indiferent de eroarea absolută.

- **Coeficientul Kendall Tau (τ):** evaluează similaritatea ordonării prin comparația directă a perechilor de câte două filme. O pereche este considerată concordantă dacă modelul respectă ordinea reală și discordantă în caz contrar, coeficientul calculându-se astfel:

$$\tau = \frac{n_c - n_d}{\frac{n(n-1)}{2}} \quad (3.8)$$

unde n_c reprezintă numărul de perechi concordante, n_d numărul de perechi discordante, iar $\frac{n(n-1)}{2}$ numărul total de combinații posibile de perechi. Valoarea obținută,

τ , reflectă probabilitatea ca algoritmul să sorteze corect orice pereche de filme extrasă aleatoriu din setul de testare.

Tabel 3.2: Rezultatele modelelor individuale (Metrici de Clasament)

Model	Spearman (ρ)	Kendall (τ)
Metadata	0.619	0.448
RoBERTa	0.554	0.393
DistilBERT	0.533	0.378
BERT	0.520	0.368
ViT	0.414	0.287
EfficientNet	0.390	0.269
ResNet50	0.382	0.263

Analizând rezultatele din Tabelul 3.2, se observă clar o ierarhie a acurateții predictive, strict dependentă de tipul datelor analizate. Metadatele oferă cel mai puternic semnal pentru aprecierea succesului, demonstrând că atributele obiective ale unui film formează o ancoră decizională mai solidă. Acestea sunt urmate de descrieri, unde modelul RoBERTa a obținut cea mai bună performanță, dovedind o capacitate superioară de a capta nuanțele semantice și complexitatea narațiunii. În cele din urmă, posterele au generat cele mai mici scoruri de corelație, lucru justificat de gradul ridicat de abstractizare și subiectivitate al unei imagini, ViT fiind totuși superior modelelor bazate pe convoluții.

Pe lângă evaluarea cantitativă a modelelor, este importantă analizarea rezultatelor calitative generate de soluția combinată. Pentru a ilustra performanța arhitecturii, au fost prezise notele a trei filme contrastante: *Interstellar* (o producție cu rating relativ mare), *Space Jam* (o producție cu rating mediu) și *A Good Day to Die Hard* (o producție cu rating relativ mic).

În Figura 3.2 sunt prezentate posterele acestor filme, alături de scorurile individuale prezise de sistem pe fiecare ramură, verdictul final al algoritmului fiind evidențiat pe rândul *PREDICTION*.

Aceste metrici confirmă faptul că, deși sistemul întâmpină dificultăți în a ghici nota exactă la nivel de zecimală, algoritmul reușește totuși să capteze o corelație privind calitatea generală. Sistemul plasează corect o producție de succes deasupra uneia cu performanțe mai slabe.



(a) Poster Interstellar

```
Title: Interstellar
Real IMDb Rating: 8.7
===== PREDICTION =====
Metadata: 7.40/10
Text:      6.24/10
Image:     6.74/10
-----
PREDICTION:      6.89/10
REAL IMDB RATING: 8.7/10
```

(b) Predicție Interstellar



(c) Poster Space Jam

```
Title: Space Jam
Real IMDb Rating: 6.5
===== PREDICTION =====
Metadata: 6.59/10
Text:      5.48/10
Image:     5.81/10
-----
PREDICTION:      6.08/10
REAL IMDB RATING: 6.5/10
```

(d) Predicție Space Jam



(e) Poster Die Hard

```
Title: A Good Day to Die Hard
Real IMDb Rating: 5.2
===== PREDICTION =====
Metadata: 5.34/10
Text:      5.88/10
Image:     5.60/10
-----
PREDICTION:      5.57/10
REAL IMDB RATING: 5.2/10
```

(f) Predicție Die Hard

Figura 3.2: Posterele și notele prezise.

3.6 Fuzionarea Modelelor

Pentru a îmbina cele trei ramuri (metadate, descriere și poster), s-a implementat o arhitectură de tip **Late Fusion**. În loc să concatenăm vectorii caracteristici extrași de RoBERTa, ViT și procesarea tabulară pentru a antrena un singur model de regresie, această variantă folosește trei modele SVR independente, oferind modularitate sistemului.

Fiecare model se specializează strict pe zona sa, predicția finală a sistemului fiind rezultatul unei medii ponderate a deciziilor finale individuale. În urma unor ajustări, ponderile finale au fost calibrate la: 50% pentru metadate, 35% pentru text și 15% pentru imagine.

Această calibrare a ponderilor nu a fost aleatorie, ci reflectă direct ierarhia puterii predictive observată pe parcurs. Deoarece metadatele au demonstrat cea mai mare capa-

citate de corelație cu notele reale, acestea funcționează ca o ancoră a predicției. Textul descriptiv ajustează acest scor, analizând firul narativ, în timp ce posterul acționează ca un element de rafinare.

Pentru a evalua eficiența acestei arhitecturi s-a realizat o comparație directă între cele două abordări: Late Fusion și *Early Fusion* (antrenată pe vectorul concatenat de caracteristici).

Tabel 3.3: Comparația metodelor de fuzionare a datelor

Metrică	Late Fusion	Early Fusion
MAE	0.649	0.635
MSE	0.763	0.728
R^2	0.423	0.395
Spearman	0.681	0.678
Kendall	0.496	0.495

Analizând datele din Tabelul 3.3, se observă că arhitectura de tip Late Fusion obține o performanță generală mai bună comparativ cu abordarea alternativă. Deși în cazul metricilor precum Spearman și Kendall diferențele sunt aproape insesizabile, decizia este fundamentată de modularitatea sistemului. Spre deosebire de Early Fusion, care transformă toată predicția într-o structură inaccesibilă, varianta aleasă permite vizualizarea exactă a verdictului fiecărei ramuri în parte, oferind și posibilitatea de a modifica ponderile decizionale în orice moment.

3.7 Implementarea interfeței grafice

Pentru a demonstra aplicabilitatea practică a cercetării, logica sistemului a fost materializată într-o aplicație web interactivă dezvoltată cu ajutorul framework-ului *Streamlit* [5]. Această interfață permite utilizatorului să introducă datele unui film și să primească un verdict aproape instantaneu.

Pentru a asigura un timp de răspuns optim, aplicația utilizează mecanisme de stocare în cache (`@st.cache_resource`). Modelele de bază foarte mari (RoBERTa și Vision Transformer), alături de instanțele SVR și funcțiile de scalare, sunt încărcate în memoria RAM o singură dată la inițializarea acesteia. Când se inițiază o predicție, procesarea textului și a imaginii, urmată de inferența modelelor SVR, se realizează în timp real.

Interfața a fost proiectată punând accent pe următoarele funcționalități cheie:

- **Fuzionarea Ponderilor:** în meniul lateral utilizatorul are la dispoziție o secțiune numită **Weight Percentage**, unde, prin intermediul unor slidere, se pot ajusta manual ponderile alocate fiecărui model în algoritmul de Late Fusion.




Figura 3.3: Secțiunea Weight Percentage

- **Pagina Database Movie:** primul modul permite verificarea oricărui film deja existent în setul de date extrase de pe IMDb și TMDB. Utilizatorul trebuie doar să introducă ID-ul, iar sistemul va prelua automat trăsăturile filmului. Rezultatul este afișat într-o secțiune numită **The Verdict**. Aici arhitectura multimodală devine vizibilă pentru că aplicația nu afișează doar o simplă notă finală, ci detaliază predicția fiecărui model în parte, alături de media lor ponderată.

The image shows a web interface for 'Rating Predictor' with a movie icon. The main heading is 'Predicting IMDb Ratings using the Metadata, Description, and Poster of the Movie'. Below this are two tabs: 'Database Movie' (selected) and 'Custom Movie'. Under the 'Database Movie' tab, there is a text input field labeled 'Enter IMDb ID:' containing the value 'tt0111161'. Below the input field is a button labeled 'Predict Rating from Database'.

Figura 3.4: Secțiunea introducerii ID-ului IMDb




Figura 3.5: Secțiunea verdictului modelelor pentru un film aflat în baza de date




Figura 3.6: Aflarea ID-ului IMDb

- **Pagina Custom Movie:** prin intermediul celui de-al doilea modul, utilizatorul poate construi un film nou, complet personalizat, introducând manual metadatele, descrierea și posterul acestuia. De această dată, algoritmul preprocesează datele brute de la zero, le trece prin arhitecturile de extragere a trăsăturilor și generează verdictul.

Rating Predictor

Predicting IMDb Ratings using the Metadata, Description, and Poster of the Movie

Database Movie Custom Movie

Upload your own data!

Movie Title: Dead Poets Society

Release Year: 1989

Runtime: 128

Genres: Comedy Drama

Upload Poster (JPG/PNG/JPEG)

Drag and drop file here
Limit 200MB per file • JPG, PNG, JPEG

Browse files

dps_poster.jpg 142.9KB

Description: Maverick teacher John Keating returns in 1959 to the prestigious New England boys' boarding school where he was once a star student, using poetry to embolden his pupils to new heights of self-expression.

Predict Rating for Uploaded Movie

Figura 3.7: Secțiunea introducerii datelor unui film personalizat (ex: Dead Poets Society)




Figura 3.8: Secțiunea verdictului modelelor pentru filmul introdus manual

Această componentă vizuală și interactivă nu reprezintă doar o simplă interfață pentru modelele alese, ci o validare directă a scopului principal al lucrării. Prin transformarea unui pipeline complex într-un instrument accesibil, sistemul demonstrează modul în care tehnologia multimodală poate asista și simplifica procesul decizional uman.

Capitolul 4

Concluzii

4.1 Sinteza lucrării și analiza performanței

Această lucrare de licență a pornit de la o problemă extrem de actuală în era digitală: suprasaturarea de conținut audio-vizual și oboseala decizională a spectatorului. Pentru a aborda această provocare, cercetarea și-a propus să investigheze în ce măsură algoritmi de inteligență artificială pot aproxima nota medie oferită unui film, folosind nu doar statistici, ci și elemente artistice precum structura narativă și identitatea vizuală.

În acest sens, a fost proiectat, antrenat și implementat un sistem hibrid bazat pe învățarea multimodală. Procesul de obținere a datelor a presupus colectarea, maparea și curățarea informațiilor de pe platformele IMDb și TMDB. Ulterior, au fost implementate arhitecturi State of the art (SOTA) pentru extragerea trăsăturilor: un model de limbaj (RoBERTa) pentru analiza descrierilor, un Vision Transformer (ViT) pentru descifrarea posterelor și un proces de encodare standardizată pentru metadate. Prin intermediul mecanismului de Late Fusion, deciziile individuale ale unor modele Support Vector Regression (SVR) au fost îmbinate ponderat pentru a genera un verdict final, întregul proces fiind accesibilizat printr-o interfață grafică interactivă.

Unul dintre cele mai importante rezultate ale acestei cercetări este concluzia legată de modul în care trebuie evaluat succesul unui sistem de inteligență artificială în domeniul artistic. Din perspectiva metricilor de eroare, cum ar fi MAE, modelele au demonstrat anumite deviații. Sistemul întâmpină dificultăți în a prezice nota exactă la nivel de zecimală (ex: o predicție de 6.89 pentru un film evaluat la 8.7).

Totuși, în ciuda deviațiilor, s-a încercat și ierarhizarea filmelor trecute prin modelele menționate anterior. Din perspectiva metricilor de clasament (Spearman și Kendall Tau), sistemul a demonstrat o performanță destul de robustă și utilă. Algoritmul a dovedit că are capacitatea de a înțelege și de a plasa un film calitativ deasupra unuia cu performanțe mai slabe, menținând intactă ordinea generală stabilită după preferințe.

Decizia de a antrena modele de regresie independent, premegător algoritmului de

Late Fusion, a permis o analiză izolată a puterii predictive pentru fiecare ramură de date în parte. În urma experimentelor, s-a observat că ierarhia importanței este următoarea: metadatele oferă cel mai puternic semnal predictiv, urmate de calitatea textului descriptiv și, în cele din urmă, de componenta vizuală a posterului. De asemenea, metricile au demonstrat că algoritmul de Late Fusion s-a dovedit superior abordării alternative, chiar dacă diferența de performanță înregistrată a fost una destul de mică.

Mai mult, diferența dintre nota prezisă și nota reală confirmă faptul că evaluarea artistică a unui film este influențată într-o oarecare măsură de o componentă subiectivă. Există o multitudine de factori externi și incontrollabili care dictează succesul unei pelicule, factori pe care niciun algoritm care analizează doar date, un text și o imagine nu îi poate capta.

În concluzie, lucrarea demonstrează cu succes posibilitatea unei legături între arhitecturile multimodale și domeniile creative, dar nu o potrivire perfectă, dată fiind existența subiectivității privitorului.

4.2 Direcții viitoare de dezvoltare

Rezultatele obținute evidențiază numeroase oportunități pentru rafinarea acestui proiect. Din punct de vedere arhitectural, modelul multimodal ar putea fi extins prin adăugarea unor noi surse de date, cum ar fi analizarea trailerelor video și a coloanelor sonore, pentru a capta cu adevărat dinamica filmului.

O direcție de dezvoltare promițătoare o reprezintă, însă, tranziția de la un predictor general de rating la un sistem de recomandare personalizat. În stadiul actual, modelul încearcă să prezică nota globală, medie, a unui film, iar preferințele publicului sunt extrem de variate. Implementarea unui sistem care să rețină istoricul vizionărilor și notele acordate personal ar permite modelului să își ajusteze verdictul în mod corespunzător.

Bibliografie

- [1] Internet Movie Database, *IMDb Non-Commercial Datasets*, 2026.
- [2] Jacob Devlin, Ming-Wei Chang, Kenton Lee și Kristina Toutanova, „BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”, în *arXiv preprint arXiv:1810.04805* (2018).
- [3] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit și Neil Houlsby, „An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale”, în *International Conference on Learning Representations*, 2020.
- [4] Kaiming He, Xiangyu Zhang, Shaoqing Ren și Jian Sun, „Deep residual learning for image recognition”, în *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 770–778.
- [5] Streamlit Inc., *Streamlit: The fastest way to build and share data apps*, 2026.
- [6] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer și Veselin Stoyanov, „RoBERTa: A Robustly Optimized BERT Pretraining Approach”, în *arXiv preprint arXiv:1907.11692* (2019).
- [7] Lakshmi Narayana, *IMDB Dataset of 50K Movie Reviews*, 2019.
- [8] Victor Sanh, Lysandre Debut, Julien Chaumond și Thomas Wolf, „DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter”, în *arXiv preprint arXiv:1910.01108* (2019).
- [9] Alex J Smola și Bernhard Schölkopf, „A tutorial on support vector regression”, în *Statistics and computing* 14.3 (2004), pp. 199–222.
- [10] Mingxing Tan și Quoc Le, „EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks”, în *International conference on machine learning*, PMLR, 2019, pp. 6105–6114.